

Beyond FFT: Frequency vs. Variance vs. Sparsity

Tae Joo Lee* Jang Ho Park* Yeseo Park*

Kyung Hee University

leetj3610@khu.ac.kr pjh0846@khu.ac.kr yeseo@khu.ac.kr

*Equal contribution.

Abstract

Large-scale pre-trained Vision Transformers (ViTs) commonly exhibit high-norm artifacts, where uninformative background patches show abnormally large output norms. The prior work LaSt-ViT attributes this to lazy aggregation and assumes that foreground patches have low channel-wise variance, selecting them via an FFT-based stability score. However, the ViT channel axis has no inherent ordering—permuting channels leaves the computation unchanged—whereas the FFT measures an ordering-dependent frequency structure rather than the statistical variance the premise claims. From this gap, we derive and

compare three score functions on a fixed backbone: TCIG (direct neighboring-channel differences), Global Variance (direct variance), and TASC (activation spikiness via an L1/L2 ratio). On ImageNet-100, all methods reach comparable Top-1 accuracy (90–92%), but in localization (PiB), TASC attains 65.31% *raw_score*—about $2.3\times$ that of FFT (28.42%). Notably, although both Global Variance and TASC are permutation invariant, they differ by roughly $4.2\times$ in *vote_count* (13.57% vs. 57.19%), showing that permutation invariance alone is insufficient and that the artifact stems from spikes in a few channels rather than from variance itself.




Figure 1. Overview of the controlled comparison. The LaSt-ViT aggregation backbone is fixed while only the stability score is replaced by FFT, TCIG, Global Variance, or TASC.

1. 서론

Vision Transformer (ViT) [1] 는 이미지 분류, 객체 탐지, 분할 등 다양한 컴퓨터 비전 과제에서 탁월한 성능을 보여왔다. 그러나 충분히 학습된 대규모 ViT 모델에서는 특정 패치 토큰의 출력 *norm* 이 주변 토큰 대비 약 10 배 이상 비정상적으로 커지는 *high-norm artifact* 현상이 관찰된다 [2].

이 현상은 주로 의미 정보가 희소한 배경 패치에서 발생하며, *dense prediction* 과 객체 탐지 등 하위 과제의 성능을 저하시키는 원인으로 지목된다.

Darcet et al. [2] 은 *high-norm artifact* 를 최초로 체계적으로 분석하였다. 이들은 해당 *outlier* 토큰이 주로 이웃 패치와의 코사인 유사도가 높은, 즉 의미 정보가 희소한 배

경패치에서 발생하며, 위치정보나 픽셀 수준의 정보를 거의 담고 있지 않은 반면 전역적인 이미지 분류 정보는 오히려 풍부하게 인코딩하고 있음을 probing 실험을 통해 규명하였다. 이러한 관찰로부터 저자들은 모델이 정보량이 적은 배경 패치를 전역의 이미지 정보의 내부 저장소로 전용한다는 가설을 제시하였으며, 이를 해결하기 위해 입력 시퀀스에 별도의 학습 가능한 register token 을 추가하는 방법을 제안하였다. Register 토큰을 도입하면 high-norm artifact 가 사라지고, dense prediction 및 객체 탐지 성능이 향상되며, DINOv2 [3] 와 같은 자기지도 학습 모델에서 해석 가능한 어텐션 맵이 회복됨을 확인하였다.

그러나 Register 접근은 artifact 를 흡수할 뿐 배경 패치가 high-norm 을 갖게 되는 근본적인 원인을 제거하지 않는다. 이에 대한 보다 직접적 접근으로 Shi et al. [4] 의 LaSt-ViT 가 제안되었다. 이들은 ViT 가 학습 초기부터 CLS 토큰을 전경 패치보다 배경 패치와 높은 유사도를 갖도록 학습하는 lazy aggregation 패턴을 보임을 밝혔다. 이를 해결하기 위해 LaSt-ViT 를 제안하며, “전경 패치는 채널 방향 분산이 작다”는 전제하에 FFT 기반 stability score 로 변동성이 낮은 전경 패치만을 선별해 channel-wise top-K pooling 으로 새로운 CLS 표현을 구성한다. 이 접근은 12 개 다운스트림 벤치마크에서 일관된 향상을 달성하였다.

그러나 본 논문은 LaSt-ViT 의 핵심 전제와 실제 측정수단 사이에 근본적인 간극이 존재함을 지적한다. 첫 번째 층위는 ViT 채널 축의 구조적 특성이다. ViT 의 채널 축 (패치 임베딩) 은 학습 과정에서 결정된 basis vector 들의 내적으로 구성되며, 채널 번호를 임의로 뒤섞어도 모델의 연산 결과와 완전히 동일하다. CNN 과 달리 채널 간 물리적 연속성이 없으므로, 채널 인덱스를 순서 있는 1 차원 신호로 취급하여 주파수 관계를 계산하는 FFT 의 ordering 전제가 이론적으로 취약하다. 더욱이 ViT 학습 과정은 이러한 채널 구조를 명시적으로 강제하지 않으므로, ordering 이 학습을 통해 자연스럽게 형성되는지 자체가 불분명하다.

두 번째 층위는 전제와 측정수단 간의 간극이다. LaSt-ViT 의 전제는 “채널 방향 분산”에 대한 것이지만, FFT 가 실질적으로 측정하는 것은 저주파 잔차 비율, 즉 ordering 에 의존하는 주파수 구조이지 순수한 통계적 분산이 아니다. 채널 값이 [1, 1, 1, 10, 10, 10, 10] 인 패치와 [1, 10, 1, 10, 1, 10, 1] 인 패치는 통계적 분산이 동일하지만 FFT score 는 전자가 훨씬 높다. 즉 FFT 는 분산이 아닌 채널 ordering 에 의존하는 주파수 구조를 측정한다.

이 간극에서 세 가지 자연스러운 탐색 방향이 도출된다. 각 방향은 “FFT score 가 실제로 측정하는 것은 무엇인가”라는 단일 물음에서 서로 다른 각도로 접근하며, 동일한 aggregation backbone 위에서 score function 만 교체하는 plug-and-play 방식으로 비교된다.

RQ1 – FFT 없이 채널 ordering 만 인정한다면 단순한 방법도 같은 효과를 내는가? FFT 의 low-pass 필터가 사실 상로컬 평활화 연산에 가깝다면, 동일한 직관을 채널 ordering 전제는 유지하되 복잡한 주파수 연산 없이 이웃 채널 간 차이를 직접 측정하는 방식으로 구현할 수 있다. 만약

이 단순화가 FFT 와 동등하거나 더 나은 성능을 보인다면, FFT 에서 유효한 정보는 주파수 분해가 아닌 국소적 채널 유사성이며 복잡한 주파수 연산은 불필요하다는 결론이 된다.

RQ2 – LaSt-ViT 의 가정대로 분산을 직접 측정하면 어떻게 되는가? LaSt-ViT 의 전제는 “채널 방향 분산”을 명시하지만 FFT 는 분산을 직접 측정하는 수단이 아니다. 따라서 ordering 전제를 완전히 폐기하고 분산을 직접 측정하는 것이 더 나은 결과를 낳는지 검증한다. RQ1 과 함께 비교하면, 두 결과의 차이로부터 채널 ordering 이 localization 능력에 실질적으로 기여하는지를 직접 분리해 낼 수 있다.

RQ3 – Artifact 의 본질은 분산 전체가 아닌 소수 채널의 spike 인가? 배경 패치에서 실제로 관찰되는 현상은 채널 전반의 분산이 크다기보다, 소수의 채널에 activation 이 비정상적으로 집중되는 spikiness 에 더 가깝다. 이 관점에서 FFT 가 효과를 보이는 이유는 주파수 원리가 아니라 spike 채널이 인접 채널과의 급격한 변화를 일으킬 때 이를 간접적으로 포착하는 부수적 효과일 수 있다. 따라서 이 spikiness 를 ordering 에 전혀 의존하지 않고 직접 측정하는 것이 더 근본적인 접근인지를 검증한다.

본 논문의 주요 기여는 다음과 같다. 첫째, LaSt-ViT 의 FFT score 가 표방하는 분산 측정과 실제 측정수단 사이의 간극을 분석하고, 이로부터 세 가지 탐색 방향을 도출하는 분석 프레임워크를 제시한다. 둘째, 각 방향을 구체화한 세 가지 score function 을 제안한다. FFT 의 ordering 전제를 인정하되 복잡한 주파수 연산을 제거하고 이웃 채널 간 변화량을 직접 측정하는 TCIG (Token-Channel Independent Gating), ordering 전제를 완전히 폐기하고 채널 분산을 직접 측정하는 Global Variance, 그리고 분산이라는 개념들을 재해석하여 채널 activation 의 spikiness 를 ordering 없이 직접 감지하는 TASC (Token Activation Spike Clipping) 가 그것이다. 셋째, 세 가지 대안을 동일한 환경에서 FFT 와 비교하고, 각 score function 이 artifact 를 포착하는 메커니즘의 차이를 실험적으로 규명한다.

2. 관련 연구

2.1. ViT 의 Artifact 와 Register Token

Darcet et al. [2] 은 충분히 학습된 대규모 ViT 에서 전체 패치의 약 2% 에 해당하는 토큰이 주변 토큰 대비 약 10 배 이상 높은 norm 을 갖는 high-norm artifact 현상을 최초로 체계적으로 분석하였다. 이들은 해당 outlier 토큰이 주로 이웃 패치와의 코사인 유사도가 높은, 즉 의미 정보가 희소한 배경 패치에서 발생하며, 위치정보나 픽셀 수준의 정보를 거의 담고 있지 않은 반면 전역적인 이미지 분류 정보는 오히려 풍부하게 인코딩하고 있음을 probing 실험을 통해 규명하였다. 이러한 관찰로부터 저자들은 모델이 정보량이 적은 배경 패치를 전역의 이미지 정보의 내부 저장소로 전용한다는 가설을 제시하였으며, 이를 해결하기 위해 입력 시퀀스에 별도의 학습 가능한 register token 을 추가하는 방법을 제안하였다. Register 토큰을 도입하면 high-norm

artifact 가 사라지고, dense prediction 및 객체 탐지 성능이 향상되며, DINOv2 [3] 와 같은 자기지도 학습 모델에서 해석 가능한 어텐션 맵이 회복됨을 확인하였다. 그러나 이 접근은 artifact 를 사후적으로 흡수하는 방식으로, 배경 패치가 high-norm 을 갖게 되는 근본적인 원인을 제거하지는 않는다는 한계가 있다.

2.2. Lazy Aggregation 과 LaSt-ViT

Shi et al. [4] 은 register 토큰이 high-norm artifact 를 제거 하더라도 CLS 토큰이 배경 패치에 집중하는 근본적 편향은 해소하지 못함을 지적한다. 이들은 토큰과 각 패치 간 유사도 유사도로 정의되는 Patch Score 와, 유사도가 가장 높은 패치가 전경 bounding box 안에 위치하는 비율을 측정하는 PiB 지표를 도입하여, ViT 가 학습 초기부터 배경 패치를 통해 전역 의미를 우회 표현하는 lazy aggregation 패턴을 정량화하였다.

이를 해결하기 위해 LaSt-ViT 는 “전경 패치는 채널 방향 분산이 작다”는 전제하에 FFT 기반 stability score 를 도입한다. 각 패치 임베딩의 채널 축에 1D FFT 를 적용하고 Gaussian low-pass 필터를 통과시킨 뒤 IFFT 로 복원한 값과 원본의 비율로 stability 를 정의한다. 변동성이 낮은, 즉 score 가 높은 전경 패치만을 선별하여 channel-wise top- K pooling 으로 새로운 CLS 표현을 구성하고, 이를 분류 헤드에 전달한다. 이 접근은 기존 ViT 구조를 변경하지 않고 score function 만 교체하는 plug-and-play 방식으로 설계되어 12 개 다운스트림 벤치마크에서 일관된 향상을 달성하였다.

그러나 FFT 는 채널 축을 순서 있는 1 차원 신호의 시간 축으로 취급하여 인접 채널들 간의 주파수 관계를 계산하는 연산으로, 전제가 명시하는 통계적 분산과 동치가 아니다. 분산이 동일 한 두 패치라도 채널 배열 순서가 다르 면 전혀 다른 FFT score 를 산출한다. 또한 표준 ViT 학습에는 이러한 채널 ordering 을 명시적으로 정렬하는 메커니즘이 존재하지 않으므로, FFT 가 가정하는 채널 구조가 실제로 형성되는지 자체가 불분명하다. 본 논문은 이 간극, 즉 전제와 측정 수단의 불일치를 출발점으로 삼아 분산을 직접 측정하거나 전제 자체를 재해석하는 대안적 score function 을 탐색한다.

3. 제안 방법

3.1. 전체 구조

본 논문은 LaSt-ViT [4] 의 channel-wise top- K aggregation 구조를 backbone 으로 고정하고, score function 만을 교체하는 plug-and-play 방식으로 세 가지 대안을 구현한다. 입력 패치 특징과 score 는

$$x \in \mathbb{R}^{B \times N \times D}, \quad S \in \mathbb{R}^{B \times N \times D} \quad (1)$$

이며, 채널별 top- K pooling 은

$$Q_{\text{CLS}}[j] = \frac{1}{K} \sum_{i \in \text{TopK}(S[:, :j])} x[i, j] \quad (2)$$

로 새로운 CLS 표현을 구성한다. 이때 $K = 7$ 로 설정한다. 손실 함수는 표준 cross-entropy 만을 사용하며, score function 외의 추가적인 학습 목표는 도입하지 않는다. 네 가지 score function—FFT (baseline), TCIG, Global Variance, TASC—은 모두 동일한 aggregation backbone 위에서 score function 만 교체되므로, 성능 차이를 온전히 score function 설계에 귀속시킬 수 있다.

3.2. FFT (Shi 2026 Baseline)

Shi et al. [4] 의 FFT 기반 score 를 그대로 재현하여 baseline 으로 사용한다. 채널 축으로 1D FFT 를 적용하고 Gaussian low-pass 필터 g 를 통과시킨 후 IFFT 로 복원한 값 $\hat{x}$ 와 원본 x 의 비율로 stability 를 정의한다.

$$\hat{x} = \text{IFFT}(\text{FFT}(x) \odot g), \quad (3)$$

$$S_{\text{FFT}} = \frac{\hat{x}}{|\hat{x} - x| + \epsilon}. \quad (4)$$

Score 가 높다는 것은 원본 x 와 저주파 통과 결과 $\hat{x}$ 의 차이가 작다는 것, 즉 해당 채널이 인접 채널들과 유사한 값을 가지며 채널 방향으로 부드럽다는 의미다. Gaussian 필터의 σ 및 모든 hyperparameter 는 Shi et al. 의 공식 구현을 그대로 사용하였다. 앞서 분석하였듯이 이 score 는 채널 배열 순서에 전역적으로 의존하며 통계적 분산의 올바른 측정 수단이 아니다.

3.3. TCIG (Token-Channel Independent Gating)

TCIG 는 FFT 의 ordering 전제를 그대로 인정하되, 복잡한 주파수 연산을 제거하고 이웃 채널 간 변화량을 더 직접적으로 측정하는 방법이다. FFT 의 Gaussian low-pass 필터가 사실상 채널 방향의 국소 평활화 연산에 가깝다는 관찰에서 출발하여, 이를 크기 $k = 7$ 의 1D AvgPool 슬라이딩 윈도우로 대체한다. 채널 축을 따라 윈도우를 슬라이딩 하여 각 채널 위치에서 이웃 채널의 평균 $\hat{x}$ 를 계산하며, 가장자리 채널의 왜곡 방지를 위해 replicate padding 을 적용한다.

원본과 평활화 결과의 차이를 정규화한 ratio 와 stability score 는

$$r = \frac{||x| - |\hat{x}||}{|x| + |\hat{x}| + \epsilon}, \quad (5)$$

$$S_{\text{TCIG}} = \exp(-r) \quad (6)$$

로 정의한다. 채널이 고를수록 $r \rightarrow 0$, spike 가 있을수록 $r \rightarrow 1$ 이 된다. 따라서 ratio 가 작으면 $S \approx 1$ 로 안정적인 채널이 Top- K 에 선택되고, ratio 가 크면 score 가 낮아져 spike 가 있는 채널이 제외된다. TCIG 는 FFT 와 마찬가지로 채널 ordering 에 의존하므로, 그 성능은 ViT 학습 과정에서 국소적 채널 ordering 구조가 실제로 형성되는지를 검증하는 간접 증거가 된다.

3.4. Global Variance

Global Variance 는 “분산을 직접 측정하면 충분하다”는 가장 단순한 가설에서 출발한다. 패치의 채널 전체에 대한

평균과 표준편차를

$$\mu = \frac{1}{D} \sum_{c=1}^D x_c, \quad \sigma = \sqrt{\frac{1}{D} \sum_{c=1}^D (x_c - \mu)^2} \quad (7)$$

로 계산하고, negative z-score 를

$$S_{GVar} = -\frac{x - \mu}{\sigma + \epsilon} \quad (8)$$

로 정의한다. 부호를 음수로 취하므로 평균보다 큰 양의 편차 채널일수록 낮은 score 를, 평균보다 작은 채널일수록 높은 score 를 받는다. 즉 이 score 는 편차를 대칭적으로 다루는 순수 분산이 아니라, 양의 편차에 선택적으로 반응하는 비대칭 지표다. 이는 FFT 가 양수 쪽 큰 활성 (spike) 을 포착하도록 설계된 방향성을 ordering 없는 변량 관점으로 옮기기 위함이다. 다만 raw_score 처럼 score 를 채널 방향으로 합산하면 양·음 편차가 $\sum_d S \approx 0$ 으로 패치마다 상쇄되므로, 이 방법에서 raw_score 는 구조적으로 불안정한 지표다. 평균과 표준편차는 집합 연산으로 계산되므로 채널 순서에 permutation invariant 하다.

3.5. TASC (Token Activation Spike Clipping)

TASC 는 전체를 “채널 분산이 작다” 가 아닌 “채널 activation 이 고르다” 로 재해석하고, 이를 채널 ordering 없이 직접 감지한다. 전경 패치는 채널 전반에 activation 이 고르게 분포하는 반면, 배경 패치는 일부 채널만 극단적으로 큰 값을 가지거나 머지는 매우 작은 값을 갖는 불균일한 분포를 보인다. Activation 분포의 균일도를 측정하기 위해 L1/L2 norm ratio 를 활용한다.

$$L_1 = \frac{1}{D} \sum_{c=1}^D |x_c|, \quad L_2 = \sqrt{\frac{1}{D} \sum_{c=1}^D x_c^2}, \quad (9)$$

$$\alpha = \frac{L_1}{L_2}, \quad \alpha \in [1/\sqrt{D}, 1]. \quad (10)$$

모든 채널의 절댓값이 동일한 완전 균일 분포에서는 $\alpha = 1$ 이며, 소수의 채널에 activation 이 집중될수록 α 는 하한인 $1/\sqrt{D}$ 방향으로 가까워진다. 클리핑 계산은 α 로 동적으로 결정된 임계값을 사용한다.

$$\tau = L_1 \cdot \alpha, \quad (11)$$

$$\hat{x} = \text{sign}(x) \cdot \min(|x|, \tau), \quad (12)$$

$$S_{TASC} = \frac{|\hat{x}|^2}{|x| + \epsilon}. \quad (13)$$

전경 패치는 activation 이 고르게 분포하므로 $\alpha \approx 1$ 이 되어 임계값이 충분히 크고 대부분의 채널이 클리핑되지 않는다. 반면 배경 패치는 $\alpha \ll 1$ 이 되어 임계값이 낮아지고 spike 채널에서 클리핑이 발생한다. TASC 는 L_1, L_2, α 가 모두 집합 연산으로 계산되므로 채널 순서에 완전히 독립적이며, 분산이 아닌 activation 의 절대적 극단성을 측정한다.

4. 실험 및 결과

4.1. 데이터셋 및 구현 세부 사항

데이터셋. 실험에는 ImageNet-1k [5] 에서 100 개 클래스를 균등 선별한 ImageNet-100 을 사용한다. Train set 은 약 130k 이미지, Validation set 은 5k 이미지로 구성된다. 전체 1k 클래스 대비 규모를 줄여 실험 효율을 확보하되, 다양한 시각적 범주를 포함하도록 구성하여 일반화 가능한 비교가 이루어지도록 하였다.

Backbone 및 학습 설정. Backbone 은 ViT-S/16 ($D = 384$, depth= 12, heads= 6) 을 사용한다. ImageNet-1k pretrained 가 중치로 초기화한 뒤 fine-tuning 하는 것을 기본 설정으로 하며, score function 은 pretrained encoder 위에 plug-and-play 방식으로 장착된다. 분류 head 는 ImageNet-1K 사전 학습 가중치에서 대상 100 개 클래스에 해당하는 행을 슬라이싱하여 초기화하였으며, score function 과 aggregator 는 랜덤 초기화하였다. Optimizer 는 AdamW, learning rate 는 5×10^{-4} 를 사용한다. 총 100 epoch, batch size 256 으로 학습하며, data augmentation 은 DeiT-III [6] 레시피를 따라 Mixup, CutMix, RandAugment 를 적용한다. Top-K 는 기본 실험에서 $K = 7$ 로 설정한다. 학습에는 NVIDIA A6000 과 RTX 2080 GPU 를 사용하였다.

4.2. 평가 지표

분류 성능은 Top-1 Accuracy 로 평가한다. 그러나 본 논문의 핵심 관심사는 각 score function 이 전경 패치를 얼마나 정확하게 식별하는가이므로, localization 성능을 주된 평가 기준으로 삼는다. Localization 평가에는 LaSt-ViT [4] 가 도입한 Point-in-Box (PiB) 지표를 사용한다. PiB 는 stability score 기준으로 가장 높은 score 를 받은 패치가 Ground Truth Bounding Box 내에 위치하는지를 측정하고, 이를 validation set 전체에 대해 평균한 값이다.

PiB 는 세 가지 변형으로 측정한다. raw_score 는 각 토큰의 stability score 를 채널 방향으로 합산하여 패치를 직접 랭킹하는 방식이며 본 논문의 주된 비교 기준이다. vote_count 는 채널별 Top-K 투표를 집계하는 방식으로 LaSt-ViT 가 직접 정의한 metric 이다. pooled 는 집계된 CLS 와의 코사인 유사도를 기반으로 하며, 선택된 패치로 만든 pooled CLS 와의 재비교이므로 순환 가능성이 있어 보조 지표로만 참고한다.

4.3. 주요 결과

Top-1 정확도는 모든 방법이 90–92% 수준으로 유사하여, score function 간 변별력은 localization 지표에서 나타난다.

RQ1 (TCIG). TCIG 는 raw_score 29.47%, pooled 18.45% 를 기록하였다. 주 지표인 raw_score 에서 TCIG(29.47%) 와 FFT(28.42%) 는 거의 동등한 수준으로, TCIG 는 FFT 에 대해 안정적인 우위를 보이지 않으며 pooled 에서는 오히려 크게 뒤쳐진다. FFT 의 ordering

Table 1. ImageNet-100, pretrained fine-tuning, $K = 7$.

Method	raw_score	vote_count	pooled	Top-1
FFT (baseline)	28.42	22.74	38.17	92.30
TCIG	29.47	22.04	18.45	92.34
Global Var	9.40	13.57	67.29	92.34
TASC	65.31	57.19	62.53	92.16
Vanilla*	—	—	48.49	90.32

*Vanilla 는선택적집계를적용하지않아분류정도가구조적으로다르며, 집계적용시의참고상한으로만사용한다.

전제를인정하면서연산만단순화한 TCIG 가 FFT 를일관되게능가하지못한다는사실은, 채널순서가없는 ViT 에서이웃채널간차이를빼는연산이전경과배경의에너지를무차별적으로건드려신호를효과적으로살리지못함을시사한다.

RQ2 (Global Variance). Global Variance 는 pooled 67.29% 로 FFT(38.17%) 를크게상회하였으나, raw_score 는 9.40% 로 FFT(28.42%) 보다현저히낮다. 이낮은 raw_score 는 score 에전경신호가없어서가아니라, 부호있는 z-score 를채널방향으로합산할때양·음편차가상쇄되어패치마다 $\sum_d S \approx 0$ 으로부터지는구조적 degeneracy 에서비롯된다. 즉 raw_score 는이방법에서신뢰지표가되지못하며, pooled 의개선은 pooled CLS 와의상호작용에서비롯된결과일가능성이크다. 신뢰가능한 vote_count 기준으로는 FFT 에미치지못해 (13.57% vs. 22.74%), 분산이큰 artifact 의본질은아니라는신호다.

RQ3 (TASC). TASC 는 raw_score 65.31%, vote_count 57.19%, pooled 62.53% 를기록하였으며, raw_score 와 vote_count 에서 1 위를차지하였다. raw_score 기준으로 FFT(28.42%) 의약 2.3 배에달한다. Global Variance 와 TASC 모두 permutation invariant 임에도 vote_count 에서 13.57% vs. 57.19% 로약 4.2 배차이가발생한다는사실은, 순열불변성자체가고성능의충분조건이아님을보여준다. Artifact 의본질이 “분산이크다” 가아니라 “소수채널에에너지가쏠린 spike” 임을강하게시사하며, FFT 의효과역시주파수원리가아닌 spike 를우연히깎은부수효과에가깝다는해석을지시한다.

그림 2은각방법의 feature norm 분포를히트맵으로시각화한것이다. Vanilla 와 FFT 는전경과배경의 norm 분포가뚜렷하게구분되지않으며, 배경영역에도높은 norm 이산발적으로나타난다. TCIG 는채널 ordering 노이즈로인해불규칙한패턴을보인다. Global Variance 는전경-배경대비가완만하게형성되나경계가불명확하다. 반면 TASC 는전경객체와배경의 norm 분포를잘구분한다.

그림 3는각방법이실제로선택한 Top- K 패치의위치를 FFT 와 TASC 간에직접비교한것이다. FFT 는전경객

Table 2. ImageNet-100, pretrained fine-tuning, $K = 98$.

Method	raw_score	vote_count	pooled	Top-1
FFT (baseline)	26.33	43.97	20.76	92.08
TCIG	18.79	22.85	21.11	92.28
Global Var	12.99	23.78	25.99	92.36
TASC	36.43	48.49	27.96	91.94
Vanilla*	—	—	48.49	90.32

체위에도일부패치를선택하지만, 배경영역의패치가혼재되어선택의일관성이낮다. 반면 TASC 는선택된패치들이전경객체의윤곽에집중적으로분포하며, 배경영역의패치가효과적으로배제됨을확인할수있다. 이는수치결과에서나타난 raw_score 차이가실제패치선택의질적차이에서비롯됨을직관적으로보여준다.

4.4. 추가분석

4.4.1. K 값에따른성능변화

LaSt-ViT [4] 는 $K = 98$ 을 sweet spot 으로주장하며, 이는 FFT 의랭킹노이즈를평균으로덜으려는시도이고 $K = 98$ 에서배경 50% 오염이강제된다고서술한다. 우리는이에두가지정정을제시한다. 첫째, K 는전역예산이아닌채널별 Top- K 로, 채널마다독립적으로 K 개패치를선택하는구조이므로 “ $K = 98 \rightarrow$ 배경 50% 오염” 산술은성립하지않는다. 둘째, LaSt-ViT 의 $K = 98$ peak 는분류정확도기준이며 localization(PiB) 에관한진술이아니다. 우리의관점에서 K 는 “오염의산술” 이아닌 “정밀도 (PiB) 가 K 에어떻게반응하는가” 로재해석되어야한다.

$K = 98$ 로넓히자 TASC pooled 가 $K = 7$ 실험의 62.53% 에서 27.96% 로크게하락하였으며, FFT 도 20.76% 로낮아졌다. 넓은 K 에서는평균에섞이는패치수가많아져 pooled 경로의변별력자체가떨어지는것으로, 이는모듈의결함이아닌집계방식의구조적특성이다. 그러나 raw_score(36.43% vs. 26.33%), vote_count(48.49% vs. 43.97%) 모두 TASC 가 FFT 를상회하여, K 가커져 pooled 가무더진환경에서도 score 자체의품질은유지된다. FFT 는 K 를넓혀도 PiB 가낮은수준에머물러랭킹품질자체의문제임이드러나며, TASC 는예리한 $K = 7$ 에서큰도약을보여얼마나키우느냐가아닌 score 품질이핵심임을시사한다.

4.4.2. 분산측정방식의영향

Global Variance 는채널전체를하나의분포로보는데, 채널마다값의크기와분포가달라전체분산을그냥구하는것이적절한지에대한문이제기될수있다. 채널전체를단일분포로보는대신크기 w 의 window 내에서만국소적으로정규화하면이문제를완화할수있는지검증하기위해, non-overlapping window 로채널을분할하여 window 내에서만분산을측정하는 Local Window Variance ($w = 8$) 를비교한다. Local Window Variance 는 window 내에서만채널순서에의존하며, window 경계를넘는채널간에는 ordering 가정을두지않는다.




Figure 2. 각 score function 의 feature norm 을 입력이미지에 overlay 한시각화. 밝은색일수록 norm 이높음을의미한다.




Figure 3. FFT 와 TASC 의 Top-K 패치선택결과시각화. 각패치에표시된수치는해당패치의 score 이며, 밝은영역일수록높은 score 를나타낸다.

Local Variance 가 Global Variance 보다 raw_score 는높지만 (24.01% vs. 9.40%) pooled 는오히려낮다

(27.61% vs. 67.29%). 국소정규화가 raw_score 기준점 수품질은일부회복시키나 pooled 경로에서는 Global

Table 3. Global Variance 와 Local Variance 비교.

Method	raw_score	vote_count	pooled	Top-1
FFT (baseline)	28.42	22.74	38.17	92.30
Global Var	9.40	13.57	67.29	92.34
Local Var ($w = 8$)	24.01	17.63	27.61	92.18

Table 4. 채널순열불변성실험.

Method	Identity	Permuted (mean $\pm$ std)	Drop	순서의존
TASC	0.9216	0.9216 $\pm$ 0.0000	+0.0000	X
Global Var	0.9236	0.9236 $\pm$ 0.0000	+0.0000	X
TCIG	0.9234	0.9222 $\pm$ 0.0009	+0.0012	O
FFT	0.9230	0.9220 $\pm$ 0.0005	+0.0010	O

Variance 에크게못미친다. 두방법모두 **vote_count** 기준으로 FFT(22.74%)를넘지못하였으며 (Global Variance 13.57%, Local Variance 17.63%), 이는분산을어떻게정규화하느냐의문제가아니라분산자체가 **artifact** 를포착하는올바른척도가아님을보여준다.

4.4.3. 채널순열불변성검증

TASC 와 Global Variance 는 5 개 seed 전부 Drop 이 0.0000 으로, 채널을어떻게섞어도결과가비트단위로동일하다. FFT 와 TCIG 는순서를섞으면수치변화가발생하여채널 ordering 에의존함이확인된다. 표 4의 Drop 은 Identity 대비순열후 Top-1 의하락폭 (Identity - Permuted 평균) 으로, 값이양수일수록순열에의해성능이떨어졌음을의미한다. FFT 의하락은 0.10%p, TCIG 는 0.12%p 에불과하여, 이는 Top-1 이 localization 에둔감한지표이기때문이며 “FFT 가무너진다” 는해석은적절하지않다. 보다중요한관찰은 Global Variance 와 TASC 의비교다. 두방법모두순열불변임에도 **vote_count** 에서 13.57% vs. 57.19% 로약 4.2 배차이가발생한다는사실은, 순열불변성자체가고성능의충분조건이아님을보여준다.

5. 분석

5.1. 주장범위의한정

본연구는 “TASC 가 ViT 의 high-norm artifact 를근본적으로제거하거나 ViT 자체를고친다” 고주장하지않는다. 본연구가다루는질문은 LaSt-ViT 가제시한 channel-wise top- K 선택적집계프레임워크를고정한조건하에서, 어떤 stability score 가전경패치를가장정확하게식별하는가이다. 즉본연구의기여는새로운아키텍처의제안아니라, 동일한집계 backbone 위에서 score function 만을교체하며그설계원리를통제된환경에서비교·규명하는데있다.

이러한범위한정은기준선설정에도그대로반영된다. 본연구의기준선은 Vanilla 가아니라 LaSt-ViT 의 FFT score 이다. Vanilla 는선택적집계를적용하지않아분류경로가구조적으로달라, 동일한 backbone 위에서 score function 의우열을비교한다는본연구의목적과부합하지않는다. 따라서 Vanilla 는직접비교대상이아니라집계

미적용시의참고상한으로만각주적으로다룬다. 모든 score function 의우열은동일 backbone, 동일 K , 동일학습조건하에서 FFT score 와의상대비교로판단된다.

5.2. 지표선택의정당성

본연구는 raw_score 를주지표로삼는다. raw_score 는각토큰의 stability score 를채널방향으로합산하여패치를직접랭킹하는방식으로, 추가적인학습이나별도의표현학습없이모두이산출한점수그자체만으로전경식별능력을평가한다. 따라서각 score function 의전체가실제전경분포에얼마나부합하는지를가장직접적으로검증할수있다.

또한단일지표에만의존하면특정지표에유리한결과만선택적으로보고한다는의혹을피하기어렵다. 이를차단하기위해 raw_score 와함께 vote_count 와 pooled 를항상병기한다. vote_count 는채널별 top- K 투표를집계하는방식으로 LaSt-ViT 가직접정의한지표이며, pooled 는집계된 CLS 와의코사인유사도에기반한다. 단, pooled 는선택된패치로구성한 pooled CLS 와의재비교라는순환가능성을내포하므로보조지표로만참고한다.

5.3. 세가설의종합해석: Frequency vs. Variance vs. Sparsity

세가지대안은각각 artifact 의본질에대해서로다른가설을대표한다. FFT 는채널 ordering 에의존하는주파수구조 (Frequency) 를, TCIG 는그주파수연산을이웃채널차이로단순화한변형을, Global Variance 와 Local Variance 는채널분산 (Variance) 을, TASC 는소수채널의 activation 집중 (Sparsity) 을측정한다.

실험결과는일관된서열을보인다. 분산계열 (Global/Local Variance) 은 ordering 을폐기한방향성은옳았으나 vote_count 기준 FFT(22.74%)를넘지못하여 (각각 13.57%, 17.63%), 분산이곧 artifact 의본질이아님을드러낸다. Ordering 을단순화한 TCIG 역시 FFT 를일관되게능가하지못한다. 반면 Sparsity 를직접측정하는 TASC 는주지표인 raw_score(65.31% vs. FFT 28.42%) 와 vote_count(57.19% vs. 22.74%) 에서 FFT 를압도하며, 보조지표인 pooled 에서도 FFT 를크게상회한다. 즉동일 backbone, 동일 K , 파라미터프리조건에서 Sparsity 가 Frequency 를주지표전반에걸쳐일관되게능가한다.

특히 Global Variance 와 TASC 는모두채널순서에완전히독립적인 permutation invariant 방법임에도, vote_count 에서 13.57% 대 57.19% 로약 4.2 배의차이를보인다. 이는순열불변성자체가고성능의충분조건이아님을명확히보여준다. 또한 ordering 에의존하는 FFT 와 TCIG 가 Global Variance 보다높은 vote_count 를기록한다는사실은, ordering 의존성의유무보다무엇을측정하는가가더결정적임을시사한다. 결국 TASC 의우위는순열불변성에서비롯되는것이아니라, L1/L2 ratio 를통해 activation 의 spikiness 를직접포착한다는측정대상의선택자체에서비롯된다. 이는 FFT 가보였던

효과역시주파수원리에기인한것이아니라, spike 채널이인접채널과급격한변화를일으킬때이를간접적으로깎아낸부수효과에가깝다는해석을뒷받침한다.

6. 결론및한계

6.1. 결론

본연구는 LaSt-ViT 의 FFT 기반 stability score 가표방하는 “채널방향분산” 이라는전제와, FFT 가실제로측정하는 ordering 의존적주파수구조사이의간극을출발점으로삼았다. 이간극에서세가지탐색방향—ordering 을단순화한 TCIG, 분산을직접측정하는 Global Variance, spikiness 를직접감지하는 TASC—을도출하고, 동일한 channel-wise top- K 집계 backbone 위에서 score function 만을교체하는통제된비교를수행하였다. 그결과 high-norm artifact 의본질은채널전반의분산이크다는데있는것이아니라소수채널에 activation 이집중되는 spike 에있으며, FFT 의효과는주파수원리가아닌이 spike 를우연히억제한부수효과에가깝다는결론에도달하였다. Activation 의 spikiness 를직접측정하는 TASC 는주지표전반에서 FFT 를일관되게능가하였고, 별도의 auxiliary loss 나추가 learnable parameter 없이동작하며, FFT/IFFT 를요구하지않는 L1/L2 ratio 기반 score 이므로기존 FFT 기반 LaSt-ViT 보다더적은연산부담으로동일한선택적집계프레임워크에결합될수있다.

6.2. 한계및향후연구

본연구의결론은몇가지조건하에서도출되었다. 첫째, 모든실험은 ImageNet-100 이라는단일데이터셋에서수행되었다. 전체 ImageNet-1k 나도메인이상이한데이터셋에서동일한서열이유지되는지는추가검증이필요하다. 둘째, backbone 은 ViT-S/16 단일구성에한정되었으며, 더큰규모의 ViT 나다른패치크기에서 spike 현상의강도와 score function 의상대적우열이달라질가능성이있다. 셋째, 본연구는 classification fine-tuning 환경에서

의 localization(PiB) 을주된평가기준으로삼았으므로, 결론은선택적집계프레임워크내 stability score 비교라는범위에한정되며 ViT 표현자체의개선을보장하지는않는다. 넷째, 본연구의주요실험결과 (표 1) 는모두단일시드기반으로측정되었으며, 다중시드에걸친분산및통계적유의성검증은향후과제로남는다.

향후연구로는 spikiness 기반측정이 DINOv2 [3] 와같은자기지도학습모델이나객체탐지·분할등 dense prediction 과제로확장될때에도일관된이점을제공하는지검증할필요가있다. 또한 artifact 의본질이소수채널의 spike 라는본연구의관찰을학습단계에서직접활용하여, 사후선택이아니라학습과정에서 spike 형성자체를억제하는방향은의미있는후속과제가될것이다.

References

- [1] A. Dosovitskiy et al., “An image is worth 16×16 words: Transformers for image recognition at scale,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2021.
- [2] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski, “Vision transformers need registers,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2024.
- [3] M. Oquab et al., “DINOv2: Learning robust visual features without supervision,” *Trans. Mach. Learn. Res. (TMLR)*, 2024.
- [4] C. Shi, Y. Yu, and S. Yang, “Vision transformers need more than registers,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2026.
- [5] O. Russakovsky et al., “ImageNet large scale visual recognition challenge,” *Int. J. Comput. Vis. (IJCV)*, vol. 115, no. 3, pp. 211–252, 2015.
- [6] H. Touvron, M. Cord, and H. Jégou, “DeiT III: Revenge of the ViT,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2022, pp. 516–533.